Universidad Santo Tomás

Facultad de Estadística — Maestría en Ciencia de Datos

Seminario de Investigación II

Concepto de dirección sobre el anteproyecto

Diseño e implementación de un framework automatizado para la evaluación de la calidad de datos en registros administrativos del sector energético en Colombia

Grupo:	Grupo 03
Estudiantes:	; ;
Director:	
Fecha:	21 de junio de 2026
Documento:	Retroalimentación técnica y notas de dirección

1. Valoración general

El anteproyecto está bien estructurado y muestra una fundamentación teórica y normativa adecuada al nivel de maestría. Integra de forma coherente los marcos de referencia (DAMA-DMBOK, ISO/IEC 25012) con el contexto de política pública (CONPES 3920 de 2018 y 4144 de 2025), define objetivos específicos trazables con las fases y el cronograma, e incorpora un tratamiento de reproducibilidad computacional (Docker, Poetry, Git) poco frecuente a este nivel.

La atención debe centrarse en lo que falta para que la propuesta sea evaluable como investigación. Existen tres vacíos metodológicos que deben cerrarse antes de avanzar a la fase de implementación: la ausencia de una pregunta de investigación explícita, la inconsistencia entre la hipótesis planteada y el diseño metodológico declarado, y la falta de una estrategia de validación con verdad de referencia para la detección de anomalías. Resueltos esos tres puntos, la propuesta es viable y de alcance pertinente.

2. Fortalezas a conservar

- Fundamentación conceptual y normativa sólida y bien articulada con el problema.
- Objetivos específicos (OE1–OE4) claros y trazables con fases y cronograma.
- Cobertura técnica de detección de anomalías (Z-score, KNN, Isolation Forest, PCA, clustering) con justificación de cada técnica.
- Reproducibilidad computacional (contenerización y control de dependencias). Constituye un diferenciador real del trabajo y debe explotarse como aporte, no como detalle de implementación.
- Consideraciones éticas adecuadas al uso de datos abiertos sin sujetos humanos.

3. Observaciones mayores

Las siguientes observaciones condicionan la solidez metodológica de la propuesta y deben atenderse de forma prioritaria.

1. **Ausencia de pregunta de investigación y de planteamiento del problema como sección.** El documento transita de la introducción a las hipótesis sin formular de manera explícita el problema ni la pregunta que lo articula. Debe incorporarse una sección que enuncie el problema y derive de él la pregunta de investigación; sin ella, el objetivo general carece de anclaje.

2. **Incoherencia entre la hipótesis y el diseño.** Se plantea una hipótesis de mejora significativa frente a métodos tradicionales (lenguaje propio del contraste estadístico), mientras que en la sección de diseño se afirma que el estudio no es cuasiexperimental y se centra en la evaluación de un artefacto. Es necesario resolver la contradicción: o se reformula el estudio bajo el marco de investigación de diseño (Design Science), prescindiendo de la hipótesis inferencial, o se define un protocolo de comparación verificable (mismos conjuntos de datos, método manual frente a framework, métricas y prueba estadística). En su forma actual, la hipótesis no es contrastable.

3. **Falta de verdad de referencia para validar la detección.** Evaluar detección de anomalías exige datos con errores conocidos para estimar precisión, exhaustividad (recall) y F1. Si se emplean únicamente datos abiertos de la CREG sin verdad de referencia, no será posible demostrar la capacidad real de detección. Se recomienda la inyección controlada de errores sintéticos (valores faltantes, duplicados, valores fuera de rango, inconsistencias estructurales) y la validación manual de una muestra de hallazgos. Debe preverse, además, el escenario en que los datos de origen estén relativamente depurados y el framework tenga poco que detectar.

4. **Métricas de evaluación del framework sin definir.** La fase de evaluación menciona indicadores de desempeño sin especificarlos. Deben establecerse de forma explícita las métricas de detección (precisión, recall, F1), de eficiencia (tiempo de ejecución, escalabilidad) y el procedimiento de contraste frente al método tradicional.

5. **Justificación de la novedad.** La brecha actual se sustenta principalmente en el alcance sectorial y geográfico. Existen herramientas abiertas consolidadas de calidad de datos (Great Expectations, AWS Deequ, ydata-profiling, Soda). El marco teórico debe contrastar la propuesta con dichas herramientas y precisar el aporte diferencial (por ejemplo, integración de reglas de negocio del sector energético, o el enfoque de reproducibilidad), de modo que la contribución no se reduzca a una aplicación localizada de técnicas existentes.

6. **Delimitación del artefacto.** No se precisa la naturaleza del entregable (librería, pipeline, paquete reutilizable o tablero). Debe incluirse una especificación concreta del artefacto: entradas, salidas, arquitectura y, preferiblemente, un diagrama de componentes.

7. **Especificación de población y muestra.** La selección por conveniencia de datos abiertos de la CREG debe concretarse: qué conjuntos específicos, cuántos, en qué periodo y con qué volumen aproximado. La afirmación de reproducibilidad pierde fuerza si las fuentes no quedan identificadas con precisión.

4. Observaciones menores (forma y consistencia)

- El resumen finaliza con un guion suelto, excede la extensión sugerida y no destaca las palabras clave ni el resultado esperado.
- Carácter residual "|" al cierre de la subsección 2.1.1.
- La sección "6. Bibliografía" aparece vacía y precede a "7. Referencias"; debe eliminarse o fusionarse.
- Referencias con errores de formato (entrada "(S/f). Gov.co" y URL del informe de la UPME con subíndices), y duplicación de la norma ISO/IEC 25012. Verificar correspondencia entre citas en el texto y la lista de referencias.
- El cronograma carece de leyenda para las columnas "Hito" y "RC"; algunas actividades figuran iniciadas en meses previos, lo que conviene aclarar.
- El marco teórico presenta reiteraciones (la importancia de la calidad y de la automatización se repite en varias subsecciones) que pueden condensarse.

5. Notas de dirección

Las siguientes notas orientan la conducción del trabajo más allá del documento.

- El equipo demuestra dominio conceptual. El avance ahora depende de fijar decisiones operativas verificables: un conjunto de datos definido, una verdad de referencia construida y unas métricas establecidas. El trabajo se evaluará por la precisión de esas definiciones.
- Se recomienda acotar el alcance y priorizar la profundidad de la validación sobre el número de técnicas incorporadas. Un framework limitado, pero evaluado con verdad de referencia y métricas claras, aporta más evidencia que uno amplio sin medición de desempeño.
- El componente de reproducibilidad debe evaluarse de forma explícita, mediante la replicación de resultados sobre conjuntos de datos distintos, e integrarse al argumento central del trabajo y no únicamente como herramienta de soporte.
- Conviene asignar de forma nominal la responsabilidad de cada componente crítico (construcción de la verdad de referencia, definición de métricas y arquitectura del artefacto), de modo que la trazabilidad de avances sea individual además de colectiva.

6. Prioridades para la próxima entrega

1. Incorporar el planteamiento del problema y la pregunta de investigación.
2. Resolver la coherencia entre hipótesis y diseño (decidir entre investigación de diseño o comparación con protocolo).
3. Definir la estrategia de validación con verdad de referencia y las métricas de desempeño.
4. Concretar los conjuntos de datos de la CREG y especificar el artefacto (arquitectura).
5. Depurar referencias, cronograma y resumen.

Concepto: aprobado con ajustes. Se recomienda atender las observaciones mayores antes de avanzar a la fase de diseño e implementación del framework.

_____

Director de trabajo de grado
Facultad de Estadística — Universidad Santo Tomás