Facultad de Estadística
Maestría en Ciencia de Datos
Anteproyecto de trabajo de grado
Junio 2026

Diseño e implementación de un framework automatizado para la evaluación de la calidad de datos en registros administrativos del sector energético en Colombia.

Design and Implementation of an Automated Framework for Data Quality Evaluation in Administrative Records of the Colombian Energy Sector.

[redacted][a]
[redacted][b]
[redacted][c]
[redacted][d]

Resumen

La investigación propone el diseño e implementación de un **framework automatizado** para evaluar la **calidad de datos** en **registros administrativos del sector energético colombiano**. Mediante un enfoque cuantitativo y reproducible, integra métricas DAMA-DMBOK, reglas de negocio y detección de anomalías sobre datos abiertos del SUI. Se espera obtener una herramienta para fortalecer la validación y monitoreo de datos.

***Palabras clave*:** (Calidad de datos, registros administrativos, sector energético, detección de anomalías, framework automatizado, reproducibilidad, gobierno de datos).

1. Introducción

En los últimos años, la transformación digital y el crecimiento exponencial del volumen de información han impulsado el uso estratégico de los datos en múltiples sectores económicos y gubernamentales. Este fenómeno, asociado al auge del Big Data y al desarrollo de herramientas basadas en inteligencia artificial, ha generado nuevas oportunidades para mejorar la toma de decisiones, fortalecer la planeación institucional y optimizar la gestión de recursos. En Colombia, esta tendencia ha sido respaldada por políticas públicas orientadas al aprovechamiento de los datos como activo estratégico del Estado, entre ellas el CONPES 3920 de 2018, relacionado con la política nacional de explotación de datos (Big Data), y el CONPES 4144 de 2025, enfocado en el desarrollo y adopción de inteligencia artificial. Ambos documentos resaltan la necesidad de garantizar datos accesibles, interoperables, reutilizables y confiables como condición para fortalecer procesos de análisis, automatización y formulación de políticas públicas.

En el sector energético colombiano, el manejo de datos representa un componente esencial para la regulación, planeación, supervisión y operación del sistema energético nacional. Entidades como el Ministerio de Minas y Energía, la Unidad de Planeación Minero Energética (UPME), la Comisión de Regulación de Energía y Gas (CREG) y XM generan y administran grandes volúmenes de información relacionados con

[a]Estudiante
[b]Estudiante
[c]Estudiante
[d]Director

tarifas, comercialización, agentes del mercado, demanda energética, regulación y operación del sistema interconectado nacional. Como parte de los esfuerzos institucionales por promover la transparencia y el acceso a la información, la CREG dispone actualmente de conjuntos de datos abiertos que facilitan el análisis de información pública y constituyen una fuente relevante para investigaciones orientadas al fortalecimiento de la gestión de datos.

Sin embargo, el incremento en la disponibilidad y diversidad de registros administrativos también ha evidenciado retos importantes relacionados con la calidad de los datos. En distintos contextos organizacionales, especialmente dentro del sector público, es frecuente encontrar registros incompletos, inconsistentes, duplicados, desactualizados o estructurados bajo formatos heterogéneos, lo cual dificulta su integración, reutilización y aprovechamiento analítico. Estas limitaciones generan reprocesos, reducen la confiabilidad de los análisis y afectan la eficiencia de los procesos institucionales que dependen de información precisa y verificable.

En el caso particular del sector energético colombiano, la existencia de múltiples actores, sistemas de información y mecanismos de reporte incrementa la complejidad en la gestión de los datos. La ausencia de estándares uniformes de validación, junto con procesos de limpieza limitados y prácticas heterogéneas de almacenamiento, puede dificultar la consistencia de los registros administrativos y limitar el aprovechamiento efectivo de la información. A ello se suma la necesidad creciente de implementar mecanismos automatizados que permitan fortalecer procesos de validación, monitoreo y detección temprana de inconsistencias.

Frente a este contexto, la presente investigación propone el diseño e implementación de un framework automatizado para la evaluación de la calidad de datos en registros administrativos del sector energético en Colombia, tomando como referencia datos abiertos de la CREG y apoyándose en metodologías asociadas a calidad de datos, reglas de negocio y detección de anomalías. Para ello, se integrarán dimensiones de calidad definidas en marcos de referencia reconocidos, como DAMA-DMBOK e ISO/IEC 25012, así como técnicas estadísticas y computacionales orientadas a la identificación de inconsistencias, valores atípicos y posibles errores presentes en los conjuntos de datos.

Desde el punto de vista metodológico, esta investigación adopta un enfoque cuantitativo y un paradigma postpositivista, orientado a la contrastación empírica mediante métricas verificables. A diferencia de estudios centrados en sujetos o fenómenos sociales, el presente trabajo se enfoca en la evaluación de un artefacto computacional, entendido como un framework diseñado para automatizar procesos de evaluación de calidad de datos y facilitar la reproducibilidad de los análisis. En este sentido, se plantea una evaluación del desempeño del framework mediante indicadores asociados a dimensiones de calidad, comparando su comportamiento frente a procedimientos tradicionales de validación.

Finalmente, se espera que este trabajo contribuya tanto al ámbito académico como al sector energético, al proporcionar una propuesta metodológica reproducible para la evaluación automatizada de la calidad de datos, favoreciendo el fortalecimiento de prácticas de gobierno de datos, el aprovechamiento de registros administrativos y la generación de información más consistente para la toma de decisiones.

2. Planteamiento del problema

El sector energético colombiano depende de grandes volúmenes de información administrativa para soportar procesos de regulación, planeación, supervisión y toma de decisiones. Entidades como la Comisión de Regulación de Energía y Gas (CREG), la Superintendencia de Servicios Públicos Domiciliarios (SSPD), la Unidad de Planeación Minero Energética (UPME) y XM generan y utilizan permanentemente registros administrativos provenientes de múltiples agentes del sector. Sin embargo, la diversidad de fuentes, formatos y mecanismos de captura incrementa la probabilidad de encontrar problemas asociados a datos faltantes, inconsistencias, duplicidades, errores de formato y falta de estandarización.

La presencia de problemas de calidad en los datos afecta la confiabilidad de los análisis realizados, limita la interoperabilidad entre sistemas y puede impactar negativamente los procesos regulatorios, operativos y

de planeación energética. Aunque actualmente existen procedimientos tradicionales de validación basados en revisiones manuales, reglas estáticas y controles operativos, estos mecanismos suelen ser costosos en términos de tiempo, difíciles de escalar y altamente dependientes del conocimiento experto.

Adicionalmente, si bien existen herramientas y frameworks consolidados para la evaluación de calidad de datos, tales como Great Expectations, Soda Core, Deequ y Pandera, estas soluciones no incorporan de manera nativa reglas regulatorias específicas del sector energético colombiano ni mecanismos explícitos de reproducibilidad orientados a registros administrativos del contexto nacional. La mayoría de investigaciones reportadas se desarrollan en contextos empresariales o académicos particulares, dejando una brecha respecto a la aplicación de estos enfoques en registros administrativos del sector energético colombiano.

En consecuencia, persiste la necesidad de diseñar mecanismos automatizados que permitan evaluar sistemáticamente la calidad de los registros administrativos del sector energético, integrando métricas reconocidas de calidad, reglas de negocio derivadas de lineamientos regulatorios y técnicas de detección de anomalías dentro de un entorno reproducible.

A partir de esta problemática surge la siguiente pregunta de investigación:

¿Cómo diseñar e implementar un framework automatizado que permita evaluar la calidad de los datos en registros administrativos del sector energético en Colombia, integrando métricas de calidad, reglas de negocio y técnicas de detección de anomalías dentro de un entorno reproducible?

3. Marco teórico y revisión de literatura

3.1. Antecedentes de investigación

La calidad de los datos ha adquirido una relevancia creciente dentro de organizaciones públicas y privadas debido al incremento en el volumen, diversidad y complejidad de la información utilizada para apoyar procesos de toma de decisiones. En este contexto, la literatura reciente ha mostrado un interés sostenido por el desarrollo de estrategias que permitan automatizar la evaluación y el monitoreo de la calidad de los datos, integrando métricas, reglas de validación y técnicas analíticas orientadas a la detección temprana de inconsistencias. No obstante, gran parte de estas investigaciones se han concentrado en contextos empresariales o financieros, mientras que las aplicaciones dirigidas a registros administrativos del sector público continúan siendo limitadas.

Diversos estudios han abordado la implementación de frameworks de gobierno y calidad de datos como mecanismos para mejorar la confiabilidad y utilidad de la información organizacional. Ortega Hoyos, Motta Altamirano y Smith Alva (2024), por ejemplo, propusieron un framework integral de gobierno y calidad de datos aplicado al proceso de emisión de pólizas vehiculares en Perú, integrando procedimientos de validación, estandarización y control de la información. Los autores encontraron mejoras en la consistencia y trazabilidad de los datos, evidenciando que la incorporación de mecanismos automatizados reduce errores derivados de procesos manuales y fortalece la calidad de los registros utilizados por las organizaciones. Sin embargo, el estudio se encuentra orientado al sector privado y no profundiza en escenarios asociados a registros administrativos gubernamentales ni en contextos regulatorios de alta heterogeneidad como el sector energético.

En paralelo, otros trabajos han resaltado la necesidad de incorporar marcos de gobierno de datos capaces de integrar dimensiones de calidad con procesos organizacionales y tecnológicos. La literatura especializada coincide en que los errores en registros administrativos suelen estar relacionados con problemas de completitud, exactitud, consistencia y estandarización, los cuales afectan directamente la interoperabilidad de los sistemas y limitan la reutilización de la información. Asimismo, se ha evidenciado que gran parte de las soluciones implementadas continúan dependiendo de revisiones manuales, auditorías periódicas o reglas estáticas de validación, lo que incrementa tiempos de procesamiento y dificulta el

monitoreo continuo de la calidad de los datos.

En investigaciones más recientes relacionadas con automatización de procesos analíticos, diferentes autores han explorado el uso de técnicas de perfilamiento estadístico y detección de anomalías para identificar valores atípicos, inconsistencias estructurales y errores de digitación en conjuntos de datos administrativos. Dentro de estas metodologías se destacan enfoques basados en estadística descriptiva, análisis de proximidad, clustering y algoritmos de aislamiento, los cuales permiten identificar registros anómalos de forma automatizada y apoyar tareas de validación tradicionalmente realizadas por analistas humanos. No obstante, la mayoría de estos estudios se centran en escenarios experimentales o datasets controlados, dejando abierta la discusión sobre su aplicabilidad en entornos institucionales caracterizados por alta heterogeneidad, estructuras cambiantes y restricciones de acceso a la información.

En el sector público, particularmente en contextos asociados a datos abiertos y gobierno digital, diferentes investigaciones han resaltado que la calidad de la información constituye un requisito fundamental para garantizar transparencia, interoperabilidad y toma de decisiones basada en evidencia. A pesar de ello, persisten vacíos relacionados con la adopción de herramientas reproducibles que permitan automatizar procesos de evaluación de calidad de datos en registros administrativos. Este desafío resulta especialmente relevante en sectores como el energético, donde entidades regulatorias y de planeación generan grandes volúmenes de información provenientes de diversas fuentes y con distintos niveles de estandarización.

En consecuencia, aunque existe evidencia sobre el uso de frameworks de calidad de datos, reglas de negocio y técnicas de detección de anomalías, aún persiste una brecha en la integración de estos enfoques dentro de soluciones automatizadas orientadas a registros administrativos del sector energético colombiano. De igual manera, son limitados los estudios que articulan mecanismos reproducibles de evaluación de calidad sobre datos abiertos institucionales, lo que justifica el desarrollo de una propuesta que combine métricas de calidad, validaciones automatizadas y técnicas de detección de anomalías aplicadas a registros administrativos del sector energético, tomando como referencia los datos abiertos publicados por la Comisión de Regulación de Energía y Gas (CREG).

3.1.1. Calidad de datos en registros administrativos

La calidad de los datos constituye uno de los elementos fundamentales para garantizar la confiabilidad, utilidad y consistencia de la información empleada en procesos organizacionales y de toma de decisiones. En términos generales, este concepto hace referencia al grado en que un conjunto de datos resulta adecuado para un propósito específico, permitiendo que la información pueda ser interpretada, reutilizada y analizada de forma precisa y consistente (DAMA International, 2017). Desde esta perspectiva, la calidad de los datos no depende únicamente de la existencia de información disponible, sino también de sus características internas, la coherencia entre registros y su capacidad para representar de manera adecuada la realidad observada.

Uno de los principales referentes conceptuales para comprender este fenómeno es el *Data Management Body of Knowledge* (DAMA-DMBOK), el cual plantea que la calidad de los datos debe entenderse como una dimensión transversal dentro de la gestión de información organizacional. Este marco reconoce que los errores presentes en los datos pueden originarse por procesos deficientes de captura, digitación, integración, transformación o almacenamiento, afectando directamente la eficiencia operativa y la confiabilidad de los análisis derivados de la información (DAMA International, 2017). En consecuencia, la evaluación de calidad requiere mecanismos sistemáticos que permitan identificar inconsistencias, establecer métricas y generar procesos de mejora continua.

De manera complementaria, la norma ISO/IEC 25012 propone un modelo orientado a la evaluación de calidad de datos mediante atributos medibles que permiten determinar el nivel de confiabilidad de los registros. Entre las dimensiones más relevantes para esta investigación se encuentran la completitud, entendida como la presencia suficiente de información requerida; la consistencia, asociada a la coherencia lógica entre atributos o registros; la exactitud, relacionada con el grado de correspondencia entre el dato y la realidad que representa; la validez, vinculada al cumplimiento de formatos y restricciones definidas;

y la unicidad, orientada a la ausencia de registros duplicados o redundantes (ISO/IEC, 2008).

Estas dimensiones adquieren especial relevancia en contextos asociados a registros administrativos, debido a que este tipo de información suele provenir de diferentes sistemas, áreas organizacionales y procesos institucionales, lo que incrementa el riesgo de inconsistencias, errores de digitación y problemas de interoperabilidad. En consecuencia, la evaluación sistemática de dimensiones de calidad se convierte en un elemento indispensable para garantizar el uso adecuado de los datos, facilitar su integración y fortalecer la toma de decisiones basada en evidencia.

En el contexto de la presente investigación, dichas dimensiones constituyen la base conceptual para operacionalizar la variable dependiente asociada a la calidad de los datos. En este sentido, el framework propuesto buscará evaluar estas características mediante métricas cuantificables y mecanismos automatizados de validación, permitiendo identificar errores, inconsistencias y anomalías presentes en registros administrativos del sector energético colombiano.

3.1.2. Registros administrativos y sector energético colombiano

Los registros administrativos constituyen una fuente fundamental de información para la gestión institucional, la formulación de políticas públicas y la toma de decisiones basadas en evidencia. Estos registros corresponden a conjuntos de datos generados durante el desarrollo de actividades operativas, regulatorias o administrativas dentro de entidades públicas y privadas, y suelen contener información relacionada con procesos, transacciones, actores y comportamientos asociados a un determinado sector o contexto institucional. A diferencia de los datos recolectados exclusivamente con fines investigativos, los registros administrativos son producidos como resultado de actividades cotidianas de gestión, lo que implica retos asociados a heterogeneidad, actualización, consistencia y control de calidad.

En el contexto colombiano, el sector energético se caracteriza por una alta complejidad institucional y operativa, debido a la participación de múltiples actores encargados de regulación, planeación, operación y supervisión del sistema energético nacional. Entre las principales entidades se encuentra el Ministerio de Minas y Energía, responsable de formular políticas relacionadas con el aprovechamiento sostenible de recursos energéticos y la planeación estratégica del sector. De manera complementaria, la Unidad de Planeación Minero Energética (UPME) participa en la planeación y elaboración de escenarios energéticos, así como en la recopilación y análisis de información relacionada con demanda, cobertura e infraestructura del sistema energético.

Por otra parte, la Comisión de Regulación de Energía y Gas (CREG) desempeña un papel central en la regulación técnica y económica del sector, estableciendo lineamientos relacionados con el funcionamiento del mercado eléctrico y de gas natural. En el marco de sus procesos regulatorios y de transparencia institucional, la CREG dispone de conjuntos de datos abiertos asociados a agentes del mercado, tarifas, regulación, comercialización y otras variables relevantes para el análisis energético. Estos registros representan una fuente de información relevante para investigaciones orientadas a la gestión y evaluación de calidad de datos, debido a su carácter administrativo, diversidad estructural y disponibilidad pública.

Asimismo, XM, como operador del Sistema Interconectado Nacional y administrador del mercado de energía mayorista, genera información relacionada con demanda, operación energética, transacciones y comportamiento del sistema eléctrico colombiano. La interacción entre estas entidades evidencia la existencia de múltiples flujos de información, diferentes formatos de almacenamiento y mecanismos diversos de captura y reporte de datos, lo que incrementa la complejidad asociada a la gestión, integración y evaluación de calidad de los registros administrativos del sector.

Desde una perspectiva de calidad de datos, esta diversidad institucional implica importantes desafíos asociados a la presencia de registros incompletos, inconsistencias estructurales, duplicidad de información y diferencias en estándares de representación. La coexistencia de múltiples fuentes, procesos regulatorios y mecanismos de actualización incrementa la necesidad de establecer estrategias automatizadas capaces de facilitar la validación, monitoreo y depuración de la información, especialmente en escenarios donde la interoperabilidad y reutilización de los datos resultan esenciales para garantizar transparencia, eficiencia

y toma de decisiones informadas.

En este sentido, los registros administrativos abiertos del sector energético colombiano, particularmente aquellos publicados por la CREG, representan un contexto pertinente para el desarrollo de mecanismos automatizados de evaluación de calidad de datos. Su naturaleza heterogénea, diversidad estructural y relevancia institucional permiten analizar cómo diferentes dimensiones de calidad pueden ser medidas y fortalecidas mediante herramientas reproducibles de validación y detección de anomalías.

3.1.3. Big Data, gobierno de datos e inteligencia artificial en el sector público

El crecimiento exponencial en la producción y disponibilidad de información digital ha impulsado transformaciones significativas en la forma en que organizaciones públicas y privadas gestionan, analizan y aprovechan los datos para apoyar procesos de toma de decisiones. Este fenómeno, asociado al desarrollo del Big Data, se caracteriza por la generación masiva de datos provenientes de múltiples fuentes, formatos y velocidades de procesamiento, lo que ha incrementado la necesidad de establecer mecanismos que permitan garantizar calidad, interoperabilidad y reutilización de la información.

En Colombia, el aprovechamiento estratégico de los datos ha sido reconocido como un elemento central para fortalecer la transformación digital del Estado y mejorar la formulación de políticas públicas. En este contexto, el Documento CONPES 3920 de 2018, denominado *Política Nacional de Explotación de Datos (Big Data)*, plantea la necesidad de desarrollar capacidades institucionales orientadas al uso eficiente de los datos como activo estratégico, promoviendo principios asociados a interoperabilidad, disponibilidad, reutilización, accesibilidad y fortalecimiento de procesos analíticos (Departamento Nacional de Planeación [DNP], 2018).

De manera complementaria, el CONPES 4144 de 2025, relacionado con la Política Nacional de Inteligencia Artificial, reconoce el papel estratégico de la automatización y la analítica avanzada dentro de procesos institucionales basados en datos. Este documento destaca que el desempeño de modelos analíticos y sistemas inteligentes depende directamente de la calidad, disponibilidad y consistencia de los datos utilizados, razón por la cual la implementación de estrategias de aseguramiento de calidad constituye una condición previa para el desarrollo responsable de tecnologías basadas en inteligencia artificial (DNP, 2025).

Desde la perspectiva del gobierno de datos, estos lineamientos evidencian que la calidad de los registros administrativos no constituye únicamente un problema técnico, sino también un requisito para garantizar transparencia, interoperabilidad, trazabilidad y eficiencia institucional. En sectores altamente regulados, como el energético, la disponibilidad de registros administrativos provenientes de diferentes actores institucionales incrementa la necesidad de contar con mecanismos sistemáticos de validación y monitoreo que permitan fortalecer la confiabilidad de la información.

En consecuencia, la presente investigación se alinea con las políticas nacionales relacionadas con explotación de datos e inteligencia artificial, al proponer un framework automatizado orientado a la evaluación de calidad de registros administrativos del sector energético colombiano. De esta manera, el proyecto busca contribuir al fortalecimiento de capacidades institucionales asociadas a la gestión de datos, promoviendo mecanismos reproducibles para la validación y detección temprana de inconsistencias en conjuntos de información abiertos y reutilizables.

3.1.4. Evaluación automatizada de calidad de datos

La evaluación de calidad de datos corresponde al conjunto de procedimientos orientados a identificar, medir y monitorear las condiciones bajo las cuales un conjunto de información puede considerarse confiable, consistente y adecuado para un propósito específico. Tradicionalmente, estos procesos han sido realizados mediante revisiones manuales, inspecciones visuales de registros, reglas estáticas implementadas por analistas o validaciones realizadas a través de hojas de cálculo y procedimientos operativos internos. Aunque estos enfoques continúan siendo ampliamente utilizados en organizaciones públicas y privadas,

presentan limitaciones relacionadas con escalabilidad, reproducibilidad y dependencia del conocimiento experto.

A medida que el volumen y complejidad de los datos ha aumentado, han surgido enfoques orientados a automatizar la evaluación de calidad mediante el uso de técnicas computacionales capaces de identificar errores, inconsistencias y anomalías de forma sistemática. Dentro de estos enfoques, el perfilamiento de datos (*data profiling*) ha adquirido una relevancia considerable, debido a que permite analizar estadísticamente conjuntos de información para identificar patrones, estructuras, distribuciones, relaciones y posibles irregularidades presentes en los registros (DAMA International, 2017).

El perfilamiento estadístico permite, por ejemplo, detectar atributos con altos porcentajes de valores nulos, identificar duplicados, reconocer errores de formato o inconsistencias semánticas y estimar comportamientos atípicos dentro de los datos. Desde esta perspectiva, la automatización de procesos de validación contribuye a reducir tiempos operativos, minimizar reprocesos y aumentar la confiabilidad de los análisis derivados de la información.

De manera complementaria, otro mecanismo ampliamente utilizado corresponde a las reglas de negocio, entendidas como restricciones lógicas definidas a partir del comportamiento esperado de los datos dentro de un contexto organizacional. Estas reglas permiten establecer validaciones automáticas relacionadas con formatos, rangos permitidos, relaciones entre atributos, obligatoriedad de campos y coherencia estructural de los registros. En sectores regulados, como el energético, este tipo de validaciones adquiere especial importancia debido a la necesidad de garantizar consistencia en la información utilizada para procesos regulatorios, operativos y de planeación.

La incorporación de técnicas automatizadas de evaluación permite complementar los mecanismos tradicionales de validación, favoreciendo procesos más reproducibles, escalables y consistentes, especialmente en escenarios caracterizados por grandes volúmenes y alta heterogeneidad de datos.

En este contexto, la presente investigación plantea la construcción de un framework automatizado orientado a la evaluación de calidad de datos en registros administrativos del sector energético colombiano, integrando mecanismos de perfilamiento estadístico, reglas de negocio y técnicas de detección de anomalías. Este enfoque busca fortalecer la evaluación sistemática de dimensiones de calidad mediante procedimientos reproducibles y medibles, facilitando la identificación temprana de inconsistencias y apoyando procesos de validación de la información.

3.1.5. Técnicas de detección de anomalías

La detección de anomalías corresponde al conjunto de procedimientos orientados a identificar registros o comportamientos que se apartan significativamente de patrones esperados dentro de un conjunto de datos. En términos generales, una anomalía puede entenderse como un valor atípico, inconsistente o inusual que potencialmente refleja errores de digitación, registros incompletos, inconsistencias estructurales, comportamientos poco frecuentes o fallas derivadas de procesos de captura y almacenamiento de información. Su identificación resulta especialmente importante en contextos administrativos, debido a que la presencia de datos erróneos puede afectar directamente procesos de análisis, generación de reportes y toma de decisiones.

Dentro de los enfoques tradicionales, los métodos estadísticos constituyen uno de los mecanismos más utilizados para la detección de valores atípicos. Entre ellos se encuentra el método *Z-score*, el cual permite medir qué tan alejado se encuentra un valor respecto a la media de una distribución, expresando dicha diferencia en términos de desviaciones estándar. Este enfoque resulta útil para identificar comportamientos extremos en variables numéricas y constituye una alternativa interpretable y de bajo costo computacional para procesos iniciales de evaluación de calidad de datos.

De manera complementaria, existen técnicas basadas en proximidad, como el algoritmo *K-Nearest Neighbors* (KNN), el cual identifica anomalías mediante el análisis de cercanía entre registros. Desde esta perspectiva, aquellos datos significativamente alejados de sus vecinos más próximos pueden considerarse

comportamientos atípicos o inconsistentes. Este tipo de técnicas resulta particularmente útil cuando la estructura de los datos presenta relaciones multivariadas que no pueden explicarse únicamente mediante estadística descriptiva.

Otro enfoque ampliamente utilizado corresponde a los métodos basados en aislamiento, como *Isolation Forest* y sus variantes extendidas. Estos algoritmos permiten detectar observaciones anómalas mediante procesos de particionamiento aleatorio de los datos, identificando registros que requieren menor cantidad de divisiones para quedar aislados. Su principal ventaja radica en la capacidad de procesar grandes volúmenes de información y detectar anomalías sin necesidad de supuestos estrictos sobre la distribución de los datos.

Asimismo, técnicas orientadas a reducción de dimensionalidad, como el *Análisis de Componentes Principales* (PCA), permiten identificar relaciones subyacentes entre variables y detectar observaciones cuyo comportamiento se aparta significativamente de estructuras dominantes dentro del dataset. En escenarios de alta dimensionalidad, este enfoque facilita la identificación de patrones irregulares y mejora la interpretación de datos complejos.

Finalmente, los métodos basados en agrupamiento o *clustering*, como *K-Means* y *DBSCAN*, permiten detectar registros anómalos a partir de agrupaciones naturales dentro de los datos. Desde esta perspectiva, aquellos registros que no logran asociarse claramente a un grupo o presentan baja densidad de similitud pueden interpretarse como observaciones atípicas.

En el marco de esta investigación, estas técnicas representan fundamentos teóricos relevantes para el diseño del framework automatizado de evaluación de calidad de datos. Su integración no busca reemplazar completamente mecanismos tradicionales de validación, sino complementarlos mediante estrategias automatizadas que permitan fortalecer procesos de detección temprana de inconsistencias y apoyar la evaluación sistemática de registros administrativos del sector energético colombiano.

3.1.6. Síntesis de las bases teóricas

Las bases teóricas presentadas permiten comprender la relación entre calidad de datos, registros administrativos, automatización y detección de anomalías como componentes fundamentales para el desarrollo de mecanismos sistemáticos de evaluación de información. Desde la perspectiva de DAMA-DMBOK e ISO/IEC 25012, la calidad de los datos puede entenderse como un atributo medible asociado a dimensiones como completitud, consistencia, exactitud, validez y unicidad, las cuales permiten evaluar el nivel de confiabilidad de los registros utilizados en procesos organizacionales y de toma de decisiones.

En contextos institucionales complejos, como el sector energético colombiano, la coexistencia de múltiples entidades, fuentes de información y mecanismos de reporte incrementa los retos relacionados con interoperabilidad, consistencia y estandarización de los datos administrativos. En este sentido, la disponibilidad de datos abiertos por parte de entidades como la Comisión de Regulación de Energía y Gas (CREG), junto con los procesos de planeación y operación desarrollados por la UPME, XM y el Ministerio de Minas y Energía, evidencia la necesidad de fortalecer mecanismos de evaluación de calidad capaces de responder a escenarios de alta heterogeneidad informacional.

De igual manera, los lineamientos nacionales asociados a explotación de datos e inteligencia artificial, particularmente aquellos establecidos en los documentos CONPES 3920 y 4144, resaltan la importancia de promover prácticas de gestión, reutilización e interoperabilidad de la información como condición necesaria para el fortalecimiento institucional y el desarrollo de capacidades analíticas basadas en datos confiables.

En conjunto, los fundamentos teóricos revisados evidencian la necesidad de integrar métricas de calidad, reglas de negocio y técnicas de detección de anomalías dentro de mecanismos reproducibles de evaluación. Esta articulación constituye el soporte conceptual del framework propuesto y orienta la definición de variables, indicadores y procedimientos metodológicos de la investigación.

En consecuencia, la presente investigación se sustenta en un conjunto integrado de fundamentos teóricos

que permiten comprender tanto el fenómeno asociado a la calidad de datos como los mecanismos metodológicos que posibilitan su evaluación automatizada. Estos elementos constituyen el soporte conceptual para el diseño del framework propuesto y orientan la operacionalización de las variables e indicadores que serán abordados en la metodología de investigación.

3.2. Hipótesis de investigación

Aunque la presente investigación se enmarca en una estrategia de Diseño y Evaluación de Artefactos (Design Science Research), se plantean hipótesis orientadas a evaluar el desempeño del framework automatizado frente a procedimientos tradicionales de validación de datos.

Hipótesis alternativa (H1):

El framework automatizado propuesto presenta un mejor desempeño que los procedimientos tradicionales de validación, evidenciado en una mayor capacidad de detección de problemas de calidad de datos, mayor cobertura de validación, menor tiempo de procesamiento y resultados reproducibles.

Hipótesis nula (H0):

El framework automatizado propuesto no presenta diferencias en su desempeño para la evaluación de la calidad de los registros administrativos del sector energético colombiano, en comparación con procedimientos tradicionales de validación.

4. Objetivos

4.1. Objetivo general

Diseñar e implementar un framework automatizado para la evaluación de la calidad de datos en registros administrativos del sector energético en Colombia, integrando métricas de calidad, reglas de negocio y técnicas de detección de anomalías aplicadas sobre datos abiertos institucionales.

4.2. Objetivos específicos

1. Identificar y definir las dimensiones, métricas e indicadores de calidad de datos más adecuados para la evaluación de registros administrativos del sector energético colombiano, tomando como referencia marcos conceptuales como DAMA-DMBOK e ISO/IEC 25012.

2. Caracterizar los registros administrativos del sector energético colombiano y establecer reglas de negocio orientadas a la validación automatizada de información proveniente de fuentes institucionales abiertas, particularmente de la Comisión de Regulación de Energía y Gas (CREG).

3. Diseñar e implementar un framework automatizado que integre técnicas de perfilamiento estadístico, validación de reglas de negocio y detección de anomalías para la evaluación de calidad de datos en registros administrativos.

4. Evaluar el desempeño del framework automatizado mediante indicadores asociados a dimensiones de calidad de datos y contrastar sus resultados frente a procedimientos tradicionales de validación de información.

5. Metodología

5.1. Paradigma de investigación

La presente investigación se desarrolla bajo un paradigma postpositivista, entendido como una perspectiva orientada a la contrastación empírica de fenómenos mediante evidencia observable, medición y análisis sistemático, reconociendo al mismo tiempo las limitaciones inherentes a los procesos de conocimiento y la imposibilidad de alcanzar explicaciones absolutas sobre la realidad (Popper, 2002). A diferencia del positivismo clásico, el postpositivismo reconoce que el conocimiento científico se construye mediante aproximaciones sucesivas, sujetas a verificación, contraste y posibilidad de refutación.

Desde esta perspectiva, el estudio busca evaluar de manera objetiva el desempeño y la utilidad del framework automatizado propuesto para la evaluación de calidad de datos en registros administrativos del sector energético colombiano. La selección de este paradigma resulta coherente con el propósito de contrastar la hipótesis planteada mediante evidencia cuantificable y métricas verificables asociadas a dimensiones de calidad de datos y criterios de desempeño del artefacto desarrollado.

Asimismo, el paradigma postpositivista resulta pertinente debido a que la investigación no pretende establecer verdades universales ni generalizaciones absolutas, sino evaluar de manera sistemática el desempeño de un artefacto computacional dentro de un contexto específico, reconociendo que los resultados pueden depender de las características particulares de los conjuntos de datos, restricciones institucionales y condiciones metodológicas del entorno de aplicación.

5.2. Enfoque de investigación

La investigación adopta un enfoque cuantitativo, dado que se fundamenta en la medición, análisis y comparación de variables mediante indicadores verificables asociados a la calidad de los datos. Este enfoque permite evaluar atributos como completitud, consistencia, exactitud, validez y unicidad mediante métricas cuantificables, facilitando el análisis objetivo de los registros administrativos y la evaluación del desempeño del framework automatizado.

El enfoque cuantitativo resulta adecuado para el presente estudio debido a que permite contrastar empíricamente la hipótesis de investigación a partir de evidencia observable y mediciones reproducibles. En este sentido, se busca evaluar el desempeño del framework automatizado mediante indicadores de calidad de datos y contrastar sus resultados frente a procedimientos tradicionales de validación.

Adicionalmente, este enfoque favorece la reproducibilidad del proceso investigativo, al apoyarse en procedimientos sistemáticos de medición y análisis que pueden ser replicados sobre diferentes conjuntos de datos administrativos del sector energético colombiano.

5.3. Diseño metodológico

La presente investigación corresponde a un estudio de carácter aplicado, debido a que busca responder a una problemática concreta relacionada con la calidad de datos en registros administrativos del sector energético colombiano mediante el diseño e implementación de una solución tecnológica. Asimismo, posee un alcance descriptivo y evaluativo, ya que pretende identificar características asociadas a la calidad de los datos y evaluar el desempeño de un framework automatizado orientado a su validación.

A diferencia de enfoques centrados en sujetos de investigación o fenómenos sociales, el presente trabajo se orienta a la evaluación de un artefacto computacional, entendido como un framework automatizado diseñado para integrar métricas de calidad, reglas de negocio, perfilamiento estadístico y técnicas de detección de anomalías sobre registros administrativos abiertos del sector energético colombiano.

Adicionalmente, la investigación se enmarca en una estrategia de Diseño y Evaluación de Artefactos

(Design Science Research), debido a que su propósito principal consiste en diseñar, implementar y evaluar un framework automatizado para la evaluación de la calidad de datos. Este enfoque metodológico se centra en la construcción de soluciones tecnológicas orientadas a resolver problemas específicos y en la valoración de su utilidad, desempeño y aplicabilidad dentro de un contexto real. En consecuencia, la contribución principal del estudio no radica en la formulación de relaciones causales entre fenómenos, sino en el desarrollo y validación de un artefacto computacional capaz de apoyar procesos de evaluación de calidad de datos en registros administrativos del sector energético colombiano.

Desde esta perspectiva, el diseño metodológico no corresponde a un estudio cuasiexperimental, puesto que no busca intervenir grupos de análisis ni establecer relaciones causales entre poblaciones. En su lugar, se enfoca en la evaluación sistemática del desempeño del framework mediante indicadores asociados a dimensiones de calidad de datos, contrastando sus resultados frente a procedimientos tradicionales de validación y depuración de información.

El diseño metodológico contempla además principios de reproducibilidad y trazabilidad computacional, incorporando herramientas tecnológicas que permitan garantizar consistencia en el procesamiento de datos, control de versiones y replicabilidad de resultados sobre conjuntos de información provenientes de fuentes abiertas institucionales.

5.4. Variables e indicadores

La presente investigación evalúa el desempeño de un framework automatizado de evaluación de calidad de datos mediante indicadores asociados a la calidad de registros administrativos del sector energético colombiano. En este sentido, se define una variable independiente relacionada con el artefacto computacional desarrollado y una variable dependiente asociada a la calidad de los datos, operacionalizada mediante dimensiones e indicadores fundamentados en marcos conceptuales como DAMA-DMBOK e ISO/IEC 25012.

5.4.1. Variable independiente

La variable independiente corresponde al framework automatizado para la evaluación de calidad de datos, entendido como un conjunto integrado de procedimientos computacionales orientados a identificar inconsistencias, validar reglas de negocio y detectar posibles anomalías presentes en registros administrativos del sector energético colombiano.

Este framework estará conformado por mecanismos de perfilamiento estadístico, validación automatizada de reglas de negocio y técnicas de detección de anomalías, permitiendo apoyar procesos de depuración, monitoreo y evaluación sistemática de información. Su implementación constituye el principal elemento de intervención metodológica dentro del estudio y será evaluada mediante su capacidad para identificar problemas asociados a la calidad de los datos.

Entre los principales componentes asociados a esta variable se encuentran:

- Perfilamiento estadístico de datos para caracterizar estructuras, distribuciones y posibles inconsistencias.
- Validación de reglas de negocio orientadas a verificar formatos, restricciones y relaciones entre atributos.
- Detección automatizada de anomalías mediante técnicas estadísticas y algoritmos de proximidad, aislamiento y agrupamiento.
- Generación de métricas e indicadores de calidad de datos para apoyar procesos de monitoreo y validación.

5.4.2. Variable dependiente

La variable dependiente corresponde a la calidad de datos en registros administrativos del sector energético colombiano, entendida como el grado en que la información disponible resulta confiable, consistente, válida y adecuada para procesos de análisis y toma de decisiones (DAMA International, 2017; ISO/IEC, 2008).

La evaluación de esta variable se realizará mediante dimensiones de calidad de datos reconocidas en literatura especializada y operacionalizadas a través de indicadores cuantificables. En el contexto de esta investigación, se priorizan las siguientes dimensiones:

- **Completitud:** corresponde al grado en que los registros contienen la información requerida sin ausencia de valores necesarios para su análisis. Será medida mediante porcentajes de datos faltantes, campos vacíos o atributos incompletos.
- **Consistencia:** hace referencia a la coherencia lógica y estructural entre registros o atributos relacionados. Se evaluará mediante reglas de validación orientadas a identificar contradicciones, incompatibilidades y errores de representación.
- **Exactitud:** se relaciona con el nivel de correspondencia entre los datos registrados y las condiciones esperadas o definidas dentro de reglas institucionales. Será evaluada mediante validaciones de rangos permitidos, formatos y coherencia de valores.
- **Validez:** corresponde al cumplimiento de restricciones, formatos o estructuras definidas para la información. Se medirá mediante verificaciones automáticas de formatos, dominios permitidos y restricciones semánticas.
- **Unicidad:** hace referencia a la ausencia de registros duplicados o redundantes dentro del conjunto de datos. Se medirá mediante identificación automática de duplicidades y redundancias estructurales.

La operacionalización de estas dimensiones permitirá evaluar el desempeño del framework automatizado mediante indicadores verificables, facilitando el contraste de resultados frente a procedimientos tradicionales de validación de información empleados en procesos manuales o semiautomatizados.

5.5. Población y muestra

La población de estudio estará conformada por registros administrativos abiertos del sector energético colombiano, particularmente aquellos publicados por la Comisión de Regulación de Energía y Gas (CREG) en el marco de sus políticas de acceso abierto y transparencia institucional. Estos registros incluyen conjuntos de datos asociados a agentes del mercado energético, regulación, comercialización, tarifas, reportes administrativos y demás estructuras de información relevantes para procesos regulatorios y de gestión sectorial.

De manera complementaria, el estudio reconoce la existencia de otras fuentes institucionales del sector energético, como la Unidad de Planeación Minero Energética (UPME), XM y el Ministerio de Minas y Energía, las cuales constituyen referentes relevantes para contextualizar procesos de planeación, operación y administración de información dentro del ecosistema energético colombiano. Sin embargo, para efectos metodológicos y de reproducibilidad, la investigación prioriza el uso de registros administrativos abiertos provenientes de la CREG como fuente principal de análisis.

En términos metodológicos, la investigación no trabaja con sujetos de estudio ni poblaciones humanas, sino con registros administrativos y conjuntos de datos estructurados. En consecuencia, la unidad de análisis corresponde a registros de información contenidos dentro de datasets institucionales abiertos,

cuya calidad será evaluada mediante dimensiones, métricas y procedimientos automatizados definidos previamente.

La muestra se establecerá mediante un muestreo no probabilístico por conveniencia, seleccionando conjuntos de datos abiertos que cumplan criterios de disponibilidad, relevancia institucional, heterogeneidad estructural y pertinencia para la evaluación de calidad de datos. Entre los criterios de selección se consideran la presencia potencial de datos faltantes, inconsistencias, duplicidades, variaciones estructurales o necesidad de validación mediante reglas de negocio.

Asimismo, se priorizarán datasets cuya estructura permita implementar mecanismos reproducibles de evaluación automatizada, facilitando la aplicación de técnicas de perfilamiento estadístico, validación de reglas de negocio y detección de anomalías. Esta estrategia favorece la replicabilidad del estudio, permitiendo que futuros investigadores puedan aplicar el framework sobre conjuntos de datos similares o provenientes de otras entidades del sector energético colombiano.

En este sentido, la selección de registros administrativos abiertos publicados por la CREG responde tanto a criterios metodológicos como prácticos, dado que su disponibilidad pública favorece procesos de trazabilidad, reproducibilidad computacional y validación de resultados dentro del contexto de investigación propuesto.

5.6. Técnicas y procedimientos de análisis

La investigación empleará un conjunto integrado de técnicas cuantitativas orientadas a la evaluación automatizada de calidad de datos sobre registros administrativos del sector energético colombiano. Estas técnicas permitirán identificar inconsistencias, valores faltantes, duplicidades, anomalías y posibles errores presentes en los datasets analizados, facilitando la evaluación sistemática de dimensiones de calidad fundamentadas en DAMA-DMBOK e ISO/IEC 25012.

El proceso metodológico se desarrollará mediante una secuencia estructurada de procedimientos orientados a la caracterización, validación y evaluación de los registros administrativos abiertos provenientes de la Comisión de Regulación de Energía y Gas (CREG). Dichos procedimientos integran técnicas estadísticas, reglas de negocio y algoritmos de detección de anomalías, buscando fortalecer la reproducibilidad y consistencia de la evaluación.

5.6.1. Perfilamiento estadístico de datos

Como etapa inicial, se implementará un proceso de perfilamiento estadístico (*data profiling*) orientado a caracterizar la estructura y comportamiento general de los conjuntos de datos analizados. Este procedimiento permitirá identificar atributos, tipos de datos, patrones de distribución, frecuencias, valores faltantes, duplicidades y posibles inconsistencias estructurales presentes en los registros.

El perfilamiento constituye un mecanismo relevante para comprender el estado inicial de calidad de los datos, permitiendo identificar problemas asociados a completitud, consistencia y validez, así como orientar la definición de reglas de negocio y mecanismos posteriores de evaluación automatizada.

5.6.2. Validación mediante reglas de negocio

Posteriormente, se definirán reglas de negocio orientadas a verificar coherencia, integridad y cumplimiento de restricciones asociadas a los registros administrativos del sector energético. Estas reglas permitirán validar automáticamente formatos, dominios de valores, relaciones entre atributos, obligatoriedad de campos y consistencia lógica entre variables.

Las reglas de negocio constituyen un mecanismo ampliamente utilizado dentro de procesos tradicionales de validación de información, debido a que permiten establecer criterios explícitos sobre el comporta-

miento esperado de los datos. En este estudio, dichas reglas serán incorporadas dentro del framework automatizado como mecanismo complementario para apoyar procesos de evaluación sistemática.

5.6.3. Métodos tradicionales de validación

Como referencia comparativa, se considerarán procedimientos tradicionales de validación de calidad de datos comúnmente empleados en contextos organizacionales, entre ellos revisión manual de registros, inspección visual de inconsistencias, validaciones mediante hojas de cálculo y aplicación de reglas estáticas definidas por analistas de datos.

La inclusión de estos mecanismos busca establecer un punto de referencia para contrastar el desempeño del framework automatizado, identificando diferencias asociadas a capacidad de detección, trazabilidad, escalabilidad y consistencia del proceso de validación.

5.6.4. Técnicas de detección de anomalías

El framework incorporará diferentes técnicas de detección de anomalías orientadas a identificar registros atípicos, inconsistencias y posibles errores presentes en los datasets analizados. La selección de estas técnicas responde a criterios asociados a interpretabilidad, reproducibilidad, escalabilidad y costo computacional.

En primer lugar, se emplearán métodos estadísticos clásicos, particularmente *Z-score*, debido a su facilidad interpretativa y capacidad para identificar observaciones alejadas respecto al comportamiento promedio de variables numéricas.

En segundo lugar, se implementarán técnicas basadas en proximidad, como *K-Nearest Neighbors* (KNN), orientadas a detectar registros anómalos mediante relaciones de similitud y distancia entre observaciones.

Asimismo, se evaluará el uso de algoritmos basados en aislamiento, particularmente *Extended Isolation Forest*, debido a su capacidad para procesar grandes volúmenes de datos y detectar anomalías sin requerir supuestos estrictos sobre distribución estadística.

De manera complementaria, se analizarán técnicas de reducción de dimensionalidad, como el *Análisis de Componentes Principales* (PCA), orientadas a identificar patrones subyacentes y comportamientos irregulares dentro de estructuras de datos multivariadas.

Finalmente, se considerarán métodos de agrupamiento (*clustering*), tales como *K-Means* y *DBSCAN*, con el propósito de identificar observaciones que se aparten significativamente de agrupaciones naturales dentro de los datos.

La selección y aplicación de estas técnicas no busca reemplazar mecanismos tradicionales de validación, sino fortalecer procesos de evaluación mediante procedimientos automatizados capaces de apoyar la detección temprana de inconsistencias y mejorar la evaluación de calidad de registros administrativos del sector energético colombiano.

5.6.5. Estrategia de validación del framework

Para evaluar el desempeño del framework automatizado se implementará una estrategia de validación basada en una verdad de referencia (ground truth), construida a partir de una muestra de registros administrativos seleccionados de los conjuntos de datos abiertos de la CREG.

La verdad de referencia será construida a partir de una muestra representativa de registros seleccionados, mediante la revisión manual de registros y la incorporación controlada de errores representativos de problemas de calidad de datos, tales como valores faltantes, registros duplicados, formatos inválidos, inconsistencias lógicas y valores atípicos. La proporción y características de los errores introducidos serán documentadas con el fin de garantizar la reproducibilidad del proceso de validación.

Los resultados generados por el framework serán contrastados con esta referencia para determinar su capacidad de identificación de problemas de calidad de datos. De esta manera, será posible evaluar objetivamente el desempeño del artefacto mediante métricas cuantificables y reproducibles.

5.6.6. Métricas de desempeño

El desempeño del framework automatizado será evaluado mediante métricas orientadas a medir su capacidad para identificar problemas de calidad de datos y apoyar procesos de validación de información. Para ello se utilizarán indicadores asociados a detección de errores, eficiencia operativa y reproducibilidad de resultados. Las principales métricas consideradas son: Precisión (Precision): proporción de problemas de calidad identificados por el framework que corresponden efectivamente a errores presentes en la verdad de referencia. Recall (Sensibilidad): proporción de errores reales contenidos en la verdad de referencia que son detectados por el framework. F1-Score: medida que combina precisión y recall para evaluar el desempeño global del mecanismo de detección. Tiempo de procesamiento: tiempo requerido para ejecutar la evaluación completa de calidad sobre cada conjunto de datos analizado. Cobertura de validación: proporción de registros y atributos que pueden ser evaluados mediante reglas de negocio, perfilamiento estadístico y técnicas de detección de anomalías. Reproducibilidad: capacidad del framework para obtener resultados consistentes cuando se ejecuta bajo las mismas condiciones y sobre los mismos conjuntos de datos.

La aceptación o rechazo de la hipótesis de investigación se realizará a partir del análisis comparativo de estas métricas entre el framework automatizado y los procedimientos tradicionales de validación, considerando especialmente la capacidad de detección de errores, cobertura de validación, tiempo de procesamiento y reproducibilidad de resultados.

5.7. Herramientas tecnológicas y reproducibilidad

El desarrollo del framework automatizado se apoyará en un conjunto de herramientas tecnológicas orientadas al procesamiento, validación y análisis reproducible de datos administrativos del sector energético colombiano. La selección de estas herramientas responde a criterios asociados a interoperabilidad, escalabilidad, reproducibilidad computacional y facilidad de integración dentro de procesos de evaluación de calidad de datos.

Como lenguaje principal de desarrollo se utilizará Python 3.12, debido a su amplio uso en procesos de ciencia de datos, análisis estadístico y automatización de flujos de procesamiento de información. Su ecosistema de bibliotecas especializadas facilita la implementación de mecanismos orientados al perfilamiento de datos, validación automatizada y detección de anomalías sobre conjuntos de información estructurados.

Para el procesamiento y transformación de datos se empleará la biblioteca *Pandas*, la cual permite realizar operaciones de limpieza, exploración, normalización y manipulación de datasets tabulares. Esta herramienta facilitará procesos asociados a identificación de valores faltantes, duplicidades, inconsistencias estructurales y preparación de datos para etapas posteriores de evaluación.

En relación con la implementación de técnicas de detección de anomalías, se utilizarán bibliotecas especializadas del ecosistema de aprendizaje automático, particularmente *Scikit-learn*, debido a su capacidad para integrar algoritmos estadísticos, métodos de proximidad, reducción de dimensionalidad y modelos orientados a identificación de patrones atípicos.

De manera complementaria, se utilizará *Jupyter Notebook* como entorno de experimentación y documentación computacional, permitiendo organizar procedimientos analíticos, registrar evidencia metodológica y facilitar procesos de trazabilidad y revisión de resultados.

Con el propósito de fortalecer la reproducibilidad computacional del estudio, el proyecto incorporará herramientas de contenerización y control de dependencias. En este sentido, se utilizará *Docker* como meca-

nismo para encapsular el entorno de ejecución del framework, garantizando consistencia entre ambientes computacionales y reduciendo problemas asociados a diferencias de configuración o compatibilidad entre sistemas.

Asimismo, se implementará *Poetry* como herramienta de gestión de dependencias, permitiendo controlar versiones de librerías, administrar paquetes utilizados dentro del proyecto y garantizar estabilidad del entorno de desarrollo. Este componente resulta especialmente relevante para asegurar trazabilidad y replicabilidad de los procedimientos metodológicos empleados.

Por otra parte, se utilizará *Git* y *GitHub* como mecanismos de control de versiones y gestión colaborativa del código fuente, facilitando seguimiento de cambios, documentación progresiva y control de modificaciones realizadas durante el desarrollo del framework.

La incorporación de estas herramientas tecnológicas busca garantizar que el proceso metodológico desarrollado sea reproducible, trazable y susceptible de replicación sobre otros conjuntos de datos administrativos del sector energético colombiano o contextos institucionales similares. En consecuencia, la reproducibilidad computacional se asume como un principio metodológico transversal dentro de la investigación, favoreciendo transparencia, consistencia y validación de resultados.

5.8. Conjunto de datos

Para el desarrollo y evaluación del framework propuesto se utilizará un conjunto de datos abierto publicado por la Comisión de Regulación de Energía y Gas (CREG) a través del Portal Nacional de Datos Abiertos de Colombia. El acceso al conjunto de datos se realizará mediante la API proporcionada por la plataforma, permitiendo la extracción automatizada de los registros y facilitando la reproducibilidad del proceso de análisis. Los datos provenientes de entidades públicas representan una fuente relevante para investigaciones orientadas a la gestión de información, debido a que corresponden a registros administrativos generados dentro de procesos institucionales y regulatorios.

Este conjunto de datos resulta adecuado para la presente investigación debido a que permite aplicar técnicas de evaluación de calidad de datos sobre información real del sector energético colombiano. Su estructura tabular facilita la implementación de procesos de perfilamiento estadístico, identificación de valores faltantes, detección de duplicidades, validación de reglas de negocio y aplicación de algoritmos de detección de anomalías. Además, al tratarse de información publicada mediante mecanismos de datos abiertos, permite garantizar trazabilidad, acceso público y replicabilidad de los experimentos realizados.

La selección de este dataset responde a la necesidad de evaluar el desempeño del framework en un escenario con características propias de los registros administrativos, donde pueden presentarse problemas asociados a heterogeneidad, consistencia, completitud y estandarización de la información. En este contexto, el conjunto de datos permite analizar cómo las técnicas automatizadas propuestas contribuyen a identificar posibles inconsistencias y fortalecer la confiabilidad de los datos utilizados para procesos de análisis y toma de decisiones dentro del sector energético colombiano.

Dataset: Superservicios - Subsidios, Contribuciones y FOES Energia Filas: 5396 Columnas: 16

Disponible en https://www.datos.gov.co/Minas-y-Energ-a/Superservicios-Subsidios-Contribuciones-y-FOES-Ene/vfjy-6fka/about_data

5.9. Delimitación del artefacto

El artefacto principal desarrollado en esta investigación corresponde a un framework automatizado para la evaluación de calidad de datos. Como componente de visualización y monitoreo, el framework incorporará un tablero de Monitoreo de Calidad de Datos orientado a presentar los resultados obtenidos durante el proceso de evaluación. El tablero permitirá centralizar los resultados obtenidos mediante procesos automatizados de perfilamiento estadístico, validación de reglas de negocio y detección de anomalías

aplicados sobre conjuntos de datos abiertos de la Comisión de Regulación de Energía y Gas (CREG).

El propósito principal del artefacto es proporcionar una herramienta de apoyo para el monitoreo y análisis de indicadores de calidad de datos, facilitando la identificación de inconsistencias, registros incompletos, duplicidades y posibles anomalías presentes en los conjuntos de información analizados.

5.9.1. Entradas del tablero

El tablero recibirá como fuente de información los resultados generados por los procesos de evaluación de calidad de datos implementados durante la investigación. Entre las principales entradas se encuentran:

- Registros administrativos abiertos provenientes de la CREG.
- Resultados del perfilamiento estadístico de datos.
- Resultados de validación de reglas de negocio.
- Resultados de detección de anomalías.
- Métricas calculadas para las dimensiones de calidad de datos.
- Fechas y metadatos asociados a cada ejecución del proceso de evaluación.

5.9.2. Salidas del tablero

El tablero presentará indicadores visuales orientados a apoyar la evaluación y monitoreo de la calidad de los datos. Entre las principales salidas se incluyen:

- Porcentaje de completitud de los registros.
- Porcentaje de unicidad de los datos.
- Número de registros con inconsistencias.
- Número de registros duplicados.
- Número de anomalías detectadas.
- Indicadores de validez y consistencia.
- Tendencias temporales de calidad de datos.
- Resumen general del estado de calidad de cada conjunto de datos analizado.

5.9.3. Arquitectura del artefacto

La arquitectura propuesta para el tablero está compuesta por cuatro componentes principales:

1. **Fuente de datos:** conjuntos de datos abiertos publicados por la CREG.
2. **Módulo de evaluación de calidad:** procesos de perfilamiento, validación y detección de anomalías implementados en Python.
3. **Repositorio de resultados:** almacenamiento de métricas e indicadores generados durante la evaluación.
4. **Tablero de visualización:** interfaz gráfica para consulta y monitoreo de indicadores de calidad.

5.9.4. Diagrama de componentes

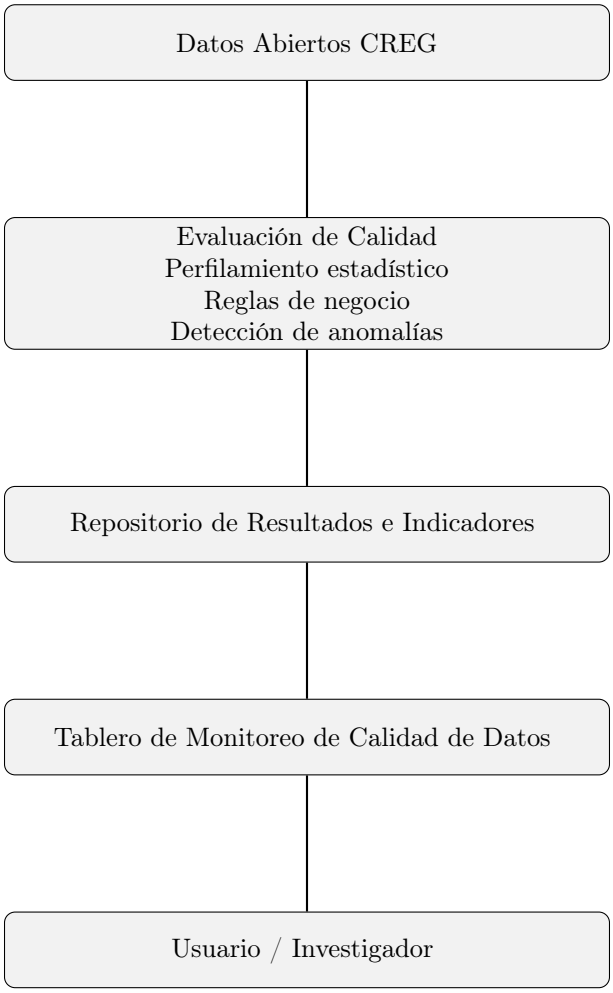


Figura 1: Arquitectura del tablero de monitoreo de calidad de datos.

5.9.5. Tecnologías previstas

Para la implementación del artefacto se utilizarán las siguientes herramientas:

- Python 3.12 para procesamiento y evaluación de datos.
- Pandas para transformación y análisis de datos.
- Scikit-learn para algoritmos de detección de anomalías.
- Power BI para construcción del tablero de visualización.
- Git y GitHub para control de versiones.
- Docker y Poetry para garantizar reproducibilidad computacional.

El alcance del artefacto se limita a la visualización y monitoreo de indicadores de calidad de datos derivados de los conjuntos de datos analizados durante la investigación. El tablero no modificará directamente

los registros fuente, sino que actuará como una herramienta de apoyo para la identificación y seguimiento de problemas de calidad de información.

5.10. Fases del proyecto

El desarrollo de la investigación se llevará a cabo mediante una secuencia estructurada de fases metodológicas orientadas al diseño, implementación y evaluación del framework automatizado para la calidad de datos en registros administrativos del sector energético colombiano. Estas fases permiten organizar sistemáticamente el proceso investigativo, garantizar trazabilidad metodológica y favorecer la reproducibilidad de resultados.

5.10.1. Fase 1. Revisión documental y fundamentación teórica

Durante esta fase se realizará la revisión de literatura científica, documentación institucional y referentes normativos relacionados con calidad de datos, gobierno de datos, registros administrativos, detección de anomalías y automatización de procesos de validación. Asimismo, se revisarán lineamientos institucionales y políticas públicas relevantes, entre ellas los documentos CONPES 3920 y 4144, DAMA-DMBOK, ISO/IEC 25012 y documentos técnicos asociados al sector energético colombiano, particularmente aquellos emitidos por la Comisión de Regulación de Energía y Gas (CREG), la Unidad de Planeación Minero Energética (UPME), XM y el Ministerio de Minas y Energía.

Esta fase permitirá construir el marco teórico, definir dimensiones de calidad, establecer criterios metodológicos y fundamentar conceptualmente el diseño del framework propuesto.

5.10.2. Fase 2. Selección, caracterización y preparación de datos

En esta etapa se identificarán y seleccionarán conjuntos de datos administrativos abiertos del sector energético colombiano, priorizando aquellos publicados por la Comisión de Regulación de Energía y Gas (CREG). Posteriormente, se realizará un proceso de caracterización orientado a identificar estructura, tipos de datos, disponibilidad, consistencia, posibles valores faltantes y condiciones iniciales de calidad.

Adicionalmente, se llevará a cabo una fase de preparación de datos orientada a organizar formatos, normalizar estructuras, documentar atributos y facilitar la posterior implementación de mecanismos automatizados de validación y análisis.

5.10.3. Fase 3. Definición de métricas y reglas de negocio

A partir de los fundamentos conceptuales establecidos en DAMA-DMBOK e ISO/IEC 25012, se definirán dimensiones, métricas e indicadores de calidad de datos orientados a evaluar atributos como completitud, consistencia, exactitud, validez y unicidad.

Asimismo, se establecerán reglas de negocio orientadas a validar formatos, restricciones, relaciones entre atributos y condiciones esperadas dentro de los registros administrativos del sector energético colombiano, permitiendo automatizar procesos de evaluación de coherencia e integridad de información.

5.10.4. Fase 4. Diseño e implementación del framework automatizado

Durante esta fase se diseñará e implementará el framework automatizado mediante Python 3.12 y bibliotecas orientadas al procesamiento y análisis de datos. El framework integrará mecanismos de perfilamiento estadístico, validación automatizada mediante reglas de negocio y técnicas de detección de anomalías orientadas a identificar inconsistencias y comportamientos atípicos en registros administrativos.

De manera complementaria, se incorporarán herramientas de reproducibilidad computacional, control de dependencias y versionamiento del entorno de desarrollo mediante Docker, Poetry y Git/GitHub.

5.10.5. Fase 5. Evaluación del framework y contraste de resultados

Posteriormente, se realizará una evaluación del desempeño del framework mediante indicadores asociados a dimensiones de calidad de datos, contrastando los resultados obtenidos frente a procedimientos tradicionales de validación de información.

Esta evaluación permitirá analizar la capacidad del framework para identificar inconsistencias, errores estructurales, duplicidades y anomalías dentro de los conjuntos de datos analizados, valorando aspectos asociados a reproducibilidad, escalabilidad, trazabilidad y apoyo a procesos de validación.

5.10.6. Fase 6. Análisis de resultados y documentación

Finalmente, se realizará el análisis e interpretación de resultados obtenidos durante la implementación del framework, identificando fortalezas, limitaciones y oportunidades de mejora del enfoque metodológico propuesto.

Asimismo, se documentarán procedimientos, configuraciones y evidencia metodológica del proyecto, garantizando trazabilidad y facilitando procesos de replicación sobre otros conjuntos de registros administrativos del sector energético colombiano.

5.11. Consideraciones éticas y limitaciones

La presente investigación no involucra intervención sobre sujetos humanos ni tratamiento de información personal sensible, dado que el objeto de estudio corresponde a registros administrativos abiertos del sector energético colombiano publicados por entidades institucionales. En consecuencia, el estudio se desarrolla sobre conjuntos de datos de acceso público, garantizando el uso responsable de la información conforme a principios de transparencia, trazabilidad y adecuada gestión de datos.

Desde una perspectiva ética, la investigación se orienta a fortalecer mecanismos de evaluación de calidad de información mediante procedimientos reproducibles y verificables, evitando alteraciones que comprometan la integridad de los registros analizados. Asimismo, se promoverá la documentación sistemática de procedimientos metodológicos, configuraciones y herramientas tecnológicas empleadas, favoreciendo transparencia y replicabilidad del proceso investigativo.

No obstante, el estudio presenta algunas limitaciones asociadas a disponibilidad, estructura y alcance de los datos abiertos institucionales. La calidad y características de los registros administrativos dependen de las condiciones de publicación, actualización y organización establecidas por las entidades responsables, lo cual puede influir sobre el comportamiento de métricas e indicadores evaluados.

De igual manera, la investigación se circunscribe principalmente a registros administrativos abiertos publicados por la Comisión de Regulación de Energía y Gas (CREG), por lo que los hallazgos obtenidos deberán interpretarse dentro del contexto específico de análisis y no necesariamente generalizarse a todos los sistemas de información del sector energético colombiano.

Finalmente, aunque el framework automatizado busca fortalecer procesos de validación y detección de inconsistencias, su implementación no pretende reemplazar completamente el juicio experto o mecanismos institucionales existentes, sino proporcionar una herramienta complementaria orientada a apoyar procesos de evaluación de calidad de datos mediante criterios sistemáticos, medibles y reproducibles.

6. Cronograma y actividades

#	OE	Actividad	Responsable	Hito	RC	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov
1	Formulación	Aprobación y ajustes del anteproyecto	, ,	Sí	Sí	X	X							
2	OE1	Revisión bibliográfica y construcción del estado del arte	, ,	No	Sí		X	X						
3	OE1	Definición de dimensiones, métricas e indicadores de calidad		Sí	Sí		X	X						
4	OE2	Recolección, caracterización y preparación de datos		No	Sí			X	X					
5	OE2	Diseño y formalización de reglas de negocio		Sí	Sí			X	X					
6	OE3	Diseño e implementación del framework automatizado	, ,	Sí	Sí					X	X	X		
7	OE3	Implementación de técnicas de detección de anomalías		No	Sí					X	X			
8	OE4	Evaluación frente a métodos tradicionales	, ,	Sí	Sí							X	X	
9	OE4	Análisis de resultados e indicadores	, ,	No	Sí							X	X	
10	Cierre	Redacción, revisión y ajustes del documento final	, ,	Sí	Sí								X	X
11	Cierre	Socialización y sustentación	, ,	Sí	Sí									X

Tabla 1: Cronograma de actividades del proyecto

Nota: Hito corresponde a una actividad o entregable relevante dentro del desarrollo del proyecto. RC (Ruta Crítica) identifica aquellas actividades cuyo retraso puede afectar directamente el cumplimiento del cronograma general de la investigación. Las actividades programadas durante los primeros meses corresponden a procesos de formulación, revisión bibliográfica y consolidación del anteproyecto desarrollados en el marco del Seminario de Investigación II, y se incluyen con el propósito de evidenciar la trazabilidad completa del proyecto.

7. Referencias

Batini, C., Cappiello, C., Francalanci, C., & Maurino, A. (2009). Methodologies for data quality assessment and improvement. *ACM Computing Surveys, 41*(3), 1–52. https://doi.org/10.1145/1541880.1541883

Cai, L., & Zhu, Y. (2015). The challenges of data quality and data quality assessment in the big data era. *Data Science Journal, 14*(2), 1–10. https://doi.org/10.5334/dsj-2015-002

Comisión de Regulación de Energía y Gas (CREG). (2022). *Regulación de calidad del servicio y reporte de información*. https://www.creg.gov.co

Criado, J. I., & Gil-García, J. R. (2013). Gobierno electrónico, gestión y políticas públicas. *Gestión y Política Pública*, 22(2), 325–359.

DAMA International. (2017). *The DAMA guide to the data management body of knowledge (DAMA-DMBOK2)* (2nd ed.). Technics Publications.

Departamento Administrativo Nacional de Estadística (DANE). (2020). *Marco de aseguramiento de la calidad estadística*. https://www.dane.gov.co

Departamento Nacional de Planeación (DNP). (2018). *Documento CONPES 3920: Política nacional de explotación de datos (Big Data)*. Gobierno de Colombia.

Departamento Nacional de Planeación (DNP). (2025). *Documento CONPES 4144: Política nacional de inteligencia artificial*. Gobierno de Colombia.

Fuentes-Moya, C. L., Caro-Gutiérrez, M. A., & Rodríguez-Ríos, A. E. (2014). Influencia de la calidad de datos en e-Government. *Revista Facultad de Ingeniería Universidad de Antioquia*, (71), 150–161.

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan

Kaufmann.

Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, M. de la L. (2003). *Metodología de la investigación* (3.ª ed.). Universidad de Pamplona. Disponible en: http://www.unipamplona.edu.co/unipamplona/portalIG/home_158/recursos/e-books/16062015/metodologia.pdf.

Herrera Castrillo, C. J. (2024). Paradigma positivista. *Boletín Científico de las Ciencias Económico Administrativas del ICEA*, 12(24), 29–32. Disponible en: https://doi.org/10.29057/icea.v12i24.12660.

International Energy Agency. (2020). *Digitalisation and energy*. https://www.iea.org

ISO/IEC. (2008). *ISO/IEC 25012: Software engineering – Software product quality requirements and evaluation (SQuaRE) – Data quality model*. International Organization for Standardization.

Librero, J., Ordiñana, R., & Peiró, S. (1998). Análisis automatizado de la calidad del conjunto mínimo de datos básicos: Implicaciones para los sistemas de ajuste de riesgos. *Gaceta Sanitaria*, 12(1), 9–21. Disponible en: https://doi.org/10.1016/S0213-9111(98)76438-6.

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. In *Proceedings of the 2008 IEEE International Conference on Data Mining* (pp. 413–422). IEEE.

Martínez, R. (2021). *Métricas de calidad para validar los conjuntos de datos abiertos públicos gubernamentales*. Google Scholar.

Ministerio de Tecnologías de la Información y las Comunicaciones (MinTIC). (2021). *Guía de calidad de datos para entidades públicas*. Gobierno de Colombia.

Ministerio de Tecnologías de la Información y las Comunicaciones, Departamento Nacional de Planeación, & Departamento Administrativo de la Presidencia de la República. (2021). *Plan nacional de infraestructura de datos*.

Ortega Hoyos, M. A., Motta Altamirano, J. E., & Smith Alva, M. A. (2024). *Propuesta de un framework de gobierno y calidad de datos para el proceso de emisión vehicular de una empresa de seguros*.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Peralta Ascue, M., Merma Aroni, J. L., Soto Carrion, C., & Jiménez Mendoza, W. (2022). *Framework de evaluación de calidad de datos basado en ISO/IEC 25012*.

Pipino, L. L., Lee, Y. W., & Wang, R. Y. (2002). Data quality assessment. *Communications of the ACM, 45*(4), 211–218. https://doi.org/10.1145/505248.506010

Popper, K. (2002). *The logic of scientific discovery*. Routledge.

Rangel-Carrillo, A. M., Maestre-Góngora, G. P., & Osorio-Sanabria, M. A. (2020). Principios, lineamientos, dimensiones y atributos para la evaluación de calidad de datos abiertos de gobierno. *Revista Aibi de Investigación, Administración e Ingeniería*, 8(2), 78–86.

Sucari Turpo, W. G., Sucari Turpo, H. A., Calsin Apaza, M. M., Mamani Condori, J. M., Choque Copari, C. A., & Gil Quispe, I. B. (2024). Paradigmas y métodos de la investigación científica. Instituto Universitario de Innovación Ciencia y Tecnología Inudi Perú. https://doi.org/10.35622/inudip.013

Reporte Integral de Sostenibilidad, Operación y Mercado 2023. (s/f). Portal XM. Recuperado el 5 de mayo de 2026, de https://www.xm.com.co/reporte-integral-de-sostenibilidad-operacion-y-mercado-2023.

Thompson, Y., Li, Y., Kang, Z., Miller, M., Wurgler, R., & Silovsky, J. (2025). Application of the data quality framework to administrative data on child maltreatment.

Troncoso-González, A., Rodríguez, A., & Caro, A. (2022). Evaluación de la calidad de datos abiertos en el contexto municipal. *Ingeniare. Revista Chilena de Ingeniería*, 30(2), 255–266.

Unidad de Planeación Minero Energética (UPME). (2025). *Informe de gestión institucional 2025*. Recuperado de https://docs.upme.gov.co/InformesGestion/Informe_de_gestion_institucional_diciembre_2025_ver_29enero2026.pdf

XM S.A. E.S.P. (2023). *Reporte de sostenibilidad, operación y mercado*. https://www.xm.com.co